

به نام هستی بخش



# گزارش تمرین سری اول

درس شناسایی الگو

نویسنده: حمیدرضا ابوئی

شماره دانشجویی: ۴۰۲۶۱۷۵۰۹

استاد: دکتر دلیری

آذر ۱۴۰۲

- ۱

```
# Gathering every feature's data type and other informations
data.info()

[4] ✓ 0.0s

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   longitude              20640 non-null  float64
1   latitude               20640 non-null  float64
2   housing_median_age     20640 non-null  float64
3   total_rooms            20640 non-null  float64
4   total_bedrooms         20433 non-null  float64
5   population             20640 non-null  float64
6   households              20640 non-null  float64
7   median_income          20640 non-null  float64
8   median_house_value     20640 non-null  float64
9   ocean_proximity        20640 non-null  object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

```
data.describe().T
✓ 0.1s
```

	count	mean	std	min	25%	50%	75%	max
longitude	20640.0	-119.569704	2.003532	-124.3500	-121.8000	-118.4900	-118.01000	-114.3100
latitude	20640.0	35.631861	2.135952	32.5400	33.9300	34.2600	37.71000	41.9500
housing_median_age	20640.0	28.639486	12.585558	1.0000	18.0000	29.0000	37.00000	52.0000
total_rooms	20640.0	2635.763081	2181.615252	2.0000	1447.7500	2127.0000	3148.00000	39320.0000
total_bedrooms	20433.0	537.870553	421.385070	1.0000	296.0000	435.0000	647.00000	6445.0000
population	20640.0	1425.476744	1132.462122	3.0000	787.0000	1166.0000	1725.00000	35682.0000
households	20640.0	499.539680	382.329753	1.0000	280.0000	409.0000	605.00000	6082.0000
median_income	20640.0	3.870671	1.899822	0.4999	2.5634	3.5348	4.74325	15.0001
median_house_value	20640.0	206855.816909	115395.615874	14999.0000	119600.0000	179700.0000	264725.00000	500001.0000

با توجه به این که • جزو دامنه اعداد نیست، احتمال این که مقادیر از دست رفته با • جایگزین شده باشند نمی‌باشد.

```
data.isnull().sum()

[9] ✓ 0.0s

... longitude      0
    latitude      0
    housing_median_age  0
    total_rooms    0
    total_bedrooms 207
    population     0
    households     0
    median_income  0
    median_house_value  0
    ocean_proximity  0
    dtype: int64
```

۲۰۷ مقدار از دست رفته است و نوع متغیر، float 64 می‌باشد.(با توجه به تصویر اول)

## Missign value management

Feature `total_rooms` has missing values. the data type of this feature is `float64`. The total number of missing values is 207. The total number of entries is 20640. That means, missing values take around 1% of our data + we have plenty of data, so I don't mind to remove all the rows containing missing value. (removing that row) However in this exercise, we replace the missing data with median

```
# Replacing missing values with median
filled_data = data.fillna(data.median())
```

Python

```
filled_data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   longitude              20640 non-null float64
1   latitude               20640 non-null float64
2   housing_median_age     20640 non-null float64
3   total_rooms            20640 non-null float64
4   total_bedrooms         20640 non-null float64
5   population             20640 non-null float64
6   households             20640 non-null float64
7   median_income          20640 non-null float64
8   median_house_value     20640 non-null float64
9   ocean_proximity        20640 non-null object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

مشاهده می شود که با این روش (جایگزینی) تعداد داده ها تغییری نمی کند.

- ۲

در این سوال برای مشخص کردن داده های پرت، از روش ۳ فاصله انحراف استاندارد استفاده می کنیم. بدین صورت که از میانگین، به اندازه سه برابر انحراف استاندارد فاصله می گیریم و اگر داده ای خارج از این بازه باشد، به عنوان داده پرت علامت خورده و حذف می شود. همچنین می توان از روش IQR در باکس پلات استفاده کرد که از Q1 به اندازه ۱.۵ برابر IQR فاصله می گیریم و هرچه داده کمتر بود حذف می شود و همچنین هرچه داده بیشتر از ۱.۵ برابر IQR بیشتر از Q3 باشد علامت خورده و حذف می شود.

می توان تعداد داده های پرت را در هر ویژگی در تصویر زیر مشاهده کرد:

```
for x in numeric_col:
    # q75,q25 = np.percentile(heart.loc[:,x],[75,25]) # a box plot of the quartile range and min/max values method
    # IQR = q75-q25
    # max = q75+(1.5*IQR)
    # min = q25-(1.5*IQR)

    max_data = filled_data[x].mean() + 3*filled_data[x].std() # Z-score method
    min_data = filled_data[x].mean() - 3*filled_data[x].std()

    filled_data.loc[filled_data[x] < min_data,x] = np.nan #filling the outliers values with 'nan'
    filled_data.loc[filled_data[x] > max_data,x] = np.nan #filling the outliers values with 'nan'
```

```
filled_data.isna().sum()

longitude      0
latitude       0
housing_median_age  0
total_rooms    373
total_bedrooms 375
population     342
households     363
median_income  345
median_house_value  0
ocean_proximity  0
dtype: int64
```

جهت نرمال سازی ابتدا ویژگی هدف را از دادگان جدا می کنیم. (در اینجا، فرض بر قیمت خانه میباشد)

سپس داده های غیر عددی جدا می شوند.

## Standardization (normalization)

Standard Scaler It standardize features by removing the mean and scaling to unit variance The standard score of a sample x is calculated as:

$$z = (x - \mu) / \sigma$$

First we want to separate our target column. We consider median\_house\_value as our target column.

Second, we separate our not numerical data.

Then we use standard scaler formula to standardize our data features.

```
# remove target
target_data = removed_outliers['median_house_value']
features = removed_outliers.drop(columns='median_house_value')
# remove object data
objective_features = features['ocean_proximity']
numeric_features = features.drop(columns='ocean_proximity')
```

در ادامه می توان پیاده سازی فرمول نرمالیزاسیون و نتیجه آن را مشاهده کرد:

```
# Using standard scaler formula
normalized_features = (numeric_features - numeric_features.mean())/numeric_features.std()
normalized_features
```

[83] ✓ 0.0s

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income
0	-1.320375	1.038968	0.964812	-1.053373	-1.258591	-1.280698	-1.250024	2.871928
1	-1.315382	1.029643	-0.645900	3.281869	2.118273	1.409283	2.531766	2.857069
2	-1.325367	1.024980	1.850704	-0.644178	-1.047753	-1.055562	-1.059440	2.205302
3	-1.330360	1.024980	1.850704	-0.778717	-0.892217	-0.975341	-0.902488	1.197497
4	-1.330360	1.024980	1.850704	-0.532642	-0.736680	-0.966284	-0.753010	0.075696
...	...	...	...	...	...	...	...	...
20635	-0.751237	1.785020	-0.323758	-0.506153	-0.411782	-0.603997	-0.487687	-1.351388
20636	-0.811146	1.789682	-0.887507	-1.180942	-1.186007	-1.236706	-1.294867	-0.729274
20637	-0.816138	1.761705	-0.968042	-0.095563	-0.028126	-0.394388	-0.102782	-1.264173
20638	-0.866063	1.761705	-0.887507	-0.370219	-0.290810	-0.738561	-0.416685	-1.159790
20639	-0.826123	1.733729	-1.048578	0.274595	0.424657	0.097287	0.259702	-0.834281

19746 rows × 8 columns

و در تصویر زیر می توان میانگین و انحراف معیار ویژگی های نرمال سازی شده را مشاهده کرد.

```
normalized_features.describe().T
```

✓ 0.1s

	count	mean	std	min	25%	50%	75%	max
longitude	19746.0	-6.251884e-15	1.0	-2.378772	-1.105700	0.536812	0.781442	2.633636
latitude	19746.0	1.148614e-15	1.0	-1.450978	-0.802846	-0.644310	0.969026	2.936736
housing_median_age	19746.0	1.763223e-17	1.0	-2.256612	-0.806971	-0.001615	0.642670	1.850704
total_rooms	19746.0	6.621081e-17	1.0	-1.665424	-0.669970	-0.215464	0.443118	4.731829
total_bedrooms	19746.0	6.387184e-17	1.0	-1.697549	-0.683971	-0.214770	0.448851	4.451317
population	19746.0	-1.370996e-16	1.0	-1.693446	-0.685512	-0.208069	0.466043	4.536596
households	19746.0	-6.162283e-17	1.0	-1.713405	-0.682008	-0.211153	0.465234	4.422661
median_income	19746.0	1.252248e-16	1.0	-2.013394	-0.738701	-0.145899	0.576508	3.640376

نرمال‌سازی داده‌های توزیع شده بر اساس چند مقیاس را به یک مقیاس تبدیل می‌کند. پس از نرمال‌سازی، همه‌ی متغیرها تأثیر مشابهی بر مدل مورد استفاده دارند و باعث بهبود پایداری و عملکرد الگوریتم یادگیری می‌شوند.

با تشکر.